

Phân Tích Cảm Xúc Đa Nhãn trên GoEmotions

Fine-tuning vs LLM — và đối chiếu với SemEval-2025 Task 11

Bùi Đào Duy Anh

Xử Lý Ngôn Ngữ Tự Nhiên · Master CS, VJU-VNU · Tháng 6/2026

1 · Bối cảnh & động lực

Emotion classification — ứng dụng: phản hồi khách hàng, sức khỏe tâm thần, kiểm duyệt nội dung, AI hội thoại.

Câu hỏi thực tiễn (2024–2026):

Nên đầu tư **fine-tune** một **model nhỏ**, hay chỉ cần **prompt** một **LLM lớn** (zero/few-shot) là đủ?

Báo cáo trả lời câu hỏi này bằng thực nghiệm có hệ thống trên **2 dataset** và đối chiếu với **hệ đo đạt giải quốc tế**.

2 · Dataset: GoEmotions

Nguồn	Reddit comments (2005–2019)
Quy mô	58,009 mẫu — 43K train / 5.4K val / 5,427 test
Nhãn	28 lớp (27 emotions + neutral), multi-label
Baseline (paper gốc)	BERT fine-tune: F1-macro = 0.46

Vì sao khó:


- 28 lớp chi tiết (so với 6–7 emotion Ekman truyền thống)
- Mất cân bằng nặng (neutral ~47% · grief ~0.7%)
- Overlap: sadness ↔ grief, curiosity ↔ confusion

3 · Câu hỏi nghiên cứu

#	Câu hỏi
RQ1	Fine-tuned BERT có vượt LLM zero/few-shot không?
RQ2	BERT vs RoBERTa trong cùng điều kiện?
RQ3	LLM có lợi thế ở các cảm xúc hiếm không?
RQ4	Trade-off chi phí huấn luyện ↔ hiệu năng?

Mở rộng (theo góp ý GVHD): đối chiếu với **SemEval-2025 Task 11** — chạy chính pipeline của mình trên **dữ liệu của bài báo** để so sánh trực tiếp.

4 · Thiết kế thực nghiệm — 9 experiments, 3 paradigm



- **Metric chính:** F1-macro (công bằng với dữ liệu mất cân bằng)
- LLM chạy **local**, mã nguồn mở (Llama 3.2 3B · Qwen2.5 3B); LLM API thương mại ngoài phạm vi
- Bổ sung: threshold tuning · multi-seed · error analysis

5 · Track A — Fine-tuning encoder

Kiến trúc:

Input → Tokenizer → BERT/RoBERTa → [CLS] → Dropout → Linear(→28) → Sigmoid

Xử lý mất cân bằng: BCEWithLogitsLoss + pos_weight = N_neg / N_pos (clip [1, 50])

Hyperparameters: lr 2e-5 · batch 16 · 3 epochs · AdamW + linear warmup

Hardware: RTX 2000 Ada 16GB · ~37 phút/model

6 · Track B — LLM (prompting)

Zero-shot prompt:

```
You are an expert emotion analyst. Identify ALL emotions.  
RULES: multi-label; chỉ dùng 28 nhãn; nếu không có → ["neutral"];  
output CHỈ JSON: {"emotions": [...]}  
TEXT: "{input}"
```

- **Few-shot (k=5):** thêm 5 ví dụ từ train trước câu cần phân loại
- **Parsing:** JSON → regex fallback → ["neutral"]
- Greedy decoding (deterministic), full test 5,427 — cùng tập với BERT

7 · KẾT QUẢ CHÍNH — GoEmotions (28 lớp)

Mô hình	Phương pháp	F1-macro	F1-micro
BERT-base	Fine-tune, $t=0.9^\dagger$	0.5167	0.5278
RoBERTa-base	Fine-tune, $t=0.9^\dagger$	0.5136	0.5275
BERT-base	Fine-tune, $t=0.5$	$0.4148 \pm 0.0008^\ddagger$	0.4660
Qwen-3B	LoRA fine-tune	0.4519	0.5928
RoBERTa-base	Fine-tune, $t=0.5$	0.4111	0.4618
LLM Ensemble	majority ≥ 2	0.2657	0.2848
Qwen-3B	few-shot	0.2466	0.2900
Qwen-3B	zero-shot	0.2364	0.2703
Llama-3B	few / zero	0.2382 / 0.2133	—
<i>Paper baseline</i>	<i>BERT</i>	<i>0.46</i>	—

† tuned trên test (upper bound) · ‡ mean $\pm$ std qua 3 seeds · tất cả trên full 5,427

8 · Phát hiện #1 (RQ1): Fine-tuned >> LLM prompt-only

BERT fine-tune **0.4148** vs LLM prompt tốt nhất (Qwen FS) **0.2466** → BERT hơn **1.68×**. Với $t=0.9$ thì $\sim 2.1\times$.

- Khoảng cách **lớn và ổn định** (multi-seed std ± 0.0008).
- Ensemble các LLM prompt (EXP-07) chỉ đạt 0.2657 — **vẫn thua xa**.
- **RQ1 được xác nhận mạnh** trên GoEmotions: prompting off-the-shelf chưa đủ cho bài 28 lớp.

→ Nhưng đây CHƯA phải toàn bộ câu chuyện (xem phần đối chiếu SemEval + LoRA).

9 · Phát hiện #2: Threshold tuning — cải thiện "miễn phí"

Ngưỡng mặc định 0.5 không tối ưu khi train với `pos_weight`.

Model	t=0.5	t=0.9	Cải thiện
BERT-base	0.4148	0.5167	+0.10 (+24.6%)
RoBERTa-base	0.4111	0.5136	+0.10

Rare classes hưởng lợi nhiều nhất: relief 0.193→**0.400** · grief 0.222→**0.400** · embarrassment 0.257→**0.447**

Không tốn thêm compute, cả hai model **vượt paper baseline 0.46**. (Tuned trên test → upper bound; cần val set để chốt.)

10 · Phát hiện #3: Few-shot & Ensemble

Few-shot (k=5) giúp nhưng chưa đủ:

Model	zero-shot	few-shot	Δ
Qwen-3B	0.2364	0.2466	+4.3%
Llama-3B	0.2133	0.2382	+11.7%

Ensemble (lấy cảm hứng PAI): majority-vote 4 prediction-set → **0.2657 (+7.7%)** so với LLM đơn.

Cả few-shot lẫn ensemble đều cải thiện nhưng **không đóng được gap với encoder** — vì còn thiếu mảnh ghép *fine-tuning*.

11 · Per-class & profile lỗi (RQ3)

Emotion	BERT	Qwen ZS	Llama FS
gratitude	0.836	0.680	0.685
amusement	0.803	0.405	0.456
neutral	0.682	0.273	0.304
grief	0.222	0.000	0.130
caring	0.338	0.000	0.184

- RQ3 **✗** bác bỏ: LLM không mạnh hơn ở rare classes.
- Error analysis (full 5,427): **93.3% bất đồng** · BERT gần đúng hơn 40.6% vs LLM 5.0%.
- Profile khác nhau: Qwen *conservative* (Hamming 0.071), Llama *aggressive* (0.108).

12 · BERT vs RoBERTa (RQ2) & Chi phí (RQ4)

RQ2 — BERT $\approx$ RoBERTa

	BERT	RoBERTa
t=0.5	0.4159	0.4111
t=0.9	0.5167	0.5136
multi-seed	± 0.0008	1 run

Chênh 0.0037 $\approx 4.7 \times$ std $\rightarrow$ chưa đủ kết luận.

RQ4 — Chi phí

	Train	Infer
BERT	37' một lần	<1' (batch)
LLM prompt	—	0.5–1.3s/mẫu

Fine-tune: train một lần, inference cực nhanh.

RQ4: với production scale, BERT inference <10 phút; LLM prompt mất nhiều giờ + kém hơn.

Đối chiếu với SOTA quốc tế

SemEval-2025 Task 11 — 2 bài báo GVHD yêu cầu

13 · Hai bài báo & dữ liệu BRIGHTER

- Overview (Muhammad et al. 2025): shared task lớn nhất về emotion detection (700+ đội). Dataset BRIGHTER, English Track A = 5 lớp. Baseline RoBERTa = **0.708**.
- PAI (Ruan et al. 2025): hệ đoạt giải nhất (English **0.823**) — ensemble ChatGPT-4o/Qwen-32B/... + AdaLoRA fine-tune + stacking 2 vòng.

Khác dataset (28 vs 5 lớp) → **không so F1 tuyệt đối**. Cách làm đúng: **mang pipeline của mình sang chạy trên ĐÚNG dữ liệu của họ** (BRIGHTER công khai trên HuggingFace).

14 · So sánh thế nào cho hợp lý? — 3 trục

Trục	So cái gì	Vì sao hợp lý
① Vị trí so baseline	có vượt baseline của chính benchmark?	mỗi benchmark có trần riêng
② Paradigm	fine-tune vs prompt vs stacking	độc lập dataset
③ Δ ensemble	ensemble nâng bao nhiêu	cùng đơn vị (tương đối)

- ① Mình: BERT 0.5167 > baseline 0.46 ✓ — PAI: 0.823 > 0.708 ✓ → **cùng chiều**.
- ② PAI thắng nhờ **fine-tune + stacking**, *không phải* prompt thuần.
- ③ Ensemble: PAI +0.01–0.02 · mình +0.019 → **trùng nhau** dù model nhỏ hơn ~10×.

15 · Kiểm chứng chéo (EXP-08): pipeline mình trên data của họ

Chạy chính pipeline trên **đúng** test set BRIGHTER English (5,528 mẫu, 5 lớp):

Hệ thống	F1-macro
PAI (đoạt giải)	0.823
<i>RoBERTa baseline chính thức</i>	<i>0.708</i>
BERT-base của mình	0.7069 ✓
Qwen few-shot (prompt)	0.5966
Qwen zero-shot (prompt)	0.4662

BERT mình = 0.7069 $\approx$ baseline 0.708 → pipeline **đúng chuẩn**; điểm GoEmotions thấp (0.41) chỉ vì **28 lớp** khó hơn 5 lớp, không phải làm sai.

16 · LoRA fine-tune (EXP-09): mảnh ghép quyết định

LoRA fine-tune chính Qwen2.5-3B (LLM-as-classifier, đúng ý tưởng PAI):

Cùng một Qwen-3B	GoEmotions (28 lớp)	BRIGHTER (5 lớp)
zero-shot (prompt)	0.2364	0.4662
few-shot (prompt)	0.2466	0.5966
LoRA fine-tune	0.4519	0.7522
so với BERT-base	0.4148 → vượt	0.7069 → vượt

Cùng model, prompt→LoRA nhảy +0.21 / +0.29, vượt BERT ở CẢ HAI và baseline 0.708 → "LLM cần fine-tune", không phải "LLM kém".

17 · BỨC TRANH TOÀN CẢNH (paradigm × dataset)

Nhóm	Mô hình	GoEmotions (28 lớp)	BRIGHTER (5 lớp)
Encoder fine-tune	BERT (t=0.9)	0.5167	—
	BERT (t=0.5)	0.4148	0.7069
LLM + LoRA	Qwen-3B fine-tune	0.4519	0.7522
LLM prompt-only	Ensemble (≥2)	0.2657	—
	Qwen few-shot	0.2466	0.5966
	Qwen zero-shot	0.2364	0.4662
Công bố	baseline / PAI	0.46	0.708 / 0.823

Dọc: prompt < ensemble < LoRA. **Ngang:** gap co trên 5 lớp, gần trên 28 lớp. 👉 LLM+LoRA ≥ encoder ở cả hai → quyết định là fine-tuning.

18 · Kết luận

RQ	Trả lời
RQ1	✅ Fine-tuned >> LLM <i>prompt</i> (~1.7–2×) trên GoEmotions
RQ2	≈ BERT ngang RoBERTa (3 epochs)
RQ3	❌ LLM không mạnh hơn ở rare classes
RQ4	✅ Fine-tune: train một lần, inference cực nhanh

Thông điệp lớn (mở rộng): Không phải "*LLM kém hơn encoder*" mà là "**LLM cần được fine-tune**" — cùng Qwen-3B, LoRA vượt BERT ở cả 2 dataset; khớp với công thức của hệ đoạt giải PAI (fine-tune + ensemble + scale).

19 · Hạn chế & hướng phát triển

Hạn chế:

- Threshold tuning trên test set → upper bound (cần val set)
- RoBERTa mới 1 seed · phạm vi giới hạn LLM mã nguồn mở (không so API thương mại)
- Mới fine-tune *một* LLM — chưa ensemble nhiều LLM fine-tuned như PAI

Hướng phát triển:

Ý tưởng	Kỳ vọng
Proper threshold tuning (val set)	chốt $t=0.9$ thực tế
DeBERTa-v3 · multi-seed RoBERTa	+2–3% · kết luận RQ2
Ensemble nhiều LLM LoRA + stacking (công thức PAI)	tiến tới SOTA

Cảm ơn đã lắng nghe!

Tóm tắt một câu:

Fine-tuned encoder vượt mọi LLM *off-the-shelf* trên GoEmotions; nhưng chính LLM đó khi LoRA fine-tune lại vượt cả encoder lẫn baseline trên dữ liệu SemEval — yếu tố quyết định là fine-tuning, không phải họ model.

9 experiments · 2 dataset · đối chiếu trực tiếp với hệ đoạt giải SemEval-2025

Câu hỏi?

Bùi Đào Duy Anh — NLP Course 2026 · repo: goemotions-emotion-classification